

INFORME DE ANÁLISIS DE NEGOCIO

Segmentación de clientes y recomendaciones estratégicas

Dataset: Online Retail II (UCI Machine Learning Repository)

Autor: Judit Giravent

Fecha: 09/2026

Herramientas utilizadas: Python 3.13, pandas, numpy, matplotlib, seaborn, Power BI Desktop

Repositorio: @jdthgp27

Índice

1. Resumen ejecutivo
2. Introducción y objetivos
3. Selección del dataset
4. Importación y exploración de datos
5. Limpieza y preparación de datos
6. Análisis Exploratorio de Datos (EDA)
7. Segmentación RFM de clientes
8. Recomendaciones de negocio
9. KPIs de seguimiento
10. Conclusiones
11. Anexos

1. Resumen ejecutivo

El presente informe analiza el comportamiento de compra de **5.852 clientes** de una tienda online del Reino Unido durante el periodo **diciembre 2009 – diciembre 2011**, a partir del dataset público *Online Retail II* del repositorio UCI.

Principales hallazgos

- **Ingresos totales del periodo:** £19.138.385,60 (aproximadamente 19,14 millones de libras).
- **Ticket medio por transacción:** £19,23.
- **Concentración extrema de ingresos:** el 22,13% de los clientes (segmento "Campeones") genera el **69,5% de los ingresos**.
- **Fuerte estacionalidad:** los ingresos se triplican en los meses de **octubre, noviembre y diciembre** (campaña navideña).
- **Dominancia geográfica:** el Reino Unido concentra el **91,9%** de las transacciones.

- **Mercados de alto valor:** Países Bajos y Australia tienen el ticket medio más alto (£105,27 y £91,91 respectivamente).
- **Alto valor en riesgo:** el segmento "En riesgo" (614 clientes) representa **£1,34M** de ingresos históricos en peligro de pérdida.

Recomendaciones clave

1. **Programa VIP** para el segmento Campeones (proteger £11,4M anuales).
2. **Campaña de reactivación urgente** para el segmento En riesgo (recuperar ~£400K).
3. **Campaña de segunda compra** para Necesitan atención (potencial de +£409K).
4. **Upselling** para Leales (potencial de +£356K).
5. **Expansión internacional** en Países Bajos y Australia.

Impacto potencial combinado: £1.165.418 adicionales en 12 meses (7,1% de crecimiento).

2. Introducción y objetivos

2.1 Contexto

El comercio electrónico de productos de regalo y decoración del hogar es un sector altamente competitivo, con márgenes ajustados y una fuerte dependencia de la fidelización del cliente. En este contexto, comprender el comportamiento de compra y segmentar a los clientes se vuelve crítico para optimizar las estrategias de marketing y maximizar el retorno de la inversión.

2.2 Objetivos del análisis

1. **Explorar** la estructura y calidad del dataset de transacciones.
2. **Limpiar y preparar** los datos para el análisis.
3. **Realizar un EDA** para detectar patrones, tendencias y anomalías.
4. **Aplicar técnicas de Business Analytics** (segmentación RFM).
5. **Desarrollar recomendaciones accionables** justificadas con datos.

2.3 Metodología

Fase	Descripción	Herramienta
1. Selección	Evaluación de datasets candidatos	Análisis comparativo
2. Exploración	Carga y análisis descriptivo	Python (pandas)
3. Limpieza	Tratamiento de nulos, outliers y duplicados	Python (pandas)
4. EDA	Correlaciones, patrones temporales y geográficos	Python (matplotlib, seaborn)
5. RFM	Segmentación de clientes	Python (pandas)

Fase	Descripción	Herramienta
6. Recomendaciones	Propuestas accionables y KPIs	Análisis de negocio

3. Selección del dataset

3.1 Candidatos evaluados

Se evaluaron tres datasets candidatos:

Criterio	Online Retail II (UCI)	Olist Brazilian E-Commerce	E-Commerce Transactions
Origen	UCI Repository	Kaggle	Kaggle
Registros	1.067.371	~100.000	25.000
Periodo	2009–2011	2016–2018	2020–2026
Datos reales	☒ Sí	☒ Sí	☐ Sintéticos
Idoneidad para RFM	Muy alta	Alta	Media

3.2 Justificación de la elección

Se seleccionó el **Online Retail II** por:

1. **Es un dataset real** de una tienda online registrada en el Reino Unido.
2. **Es el estándar de referencia** para análisis RFM en la industria.
3. **Volumen suficiente** (más de 1M de transacciones) para análisis robusto.
4. **Nivel de suciedad adecuado** (nulos, cancelaciones, outliers) para demostrar habilidades de limpieza.
5. **Bien documentado y reproducible.**

3.3 Ficha técnica

Característica	Valor
Nombre	Online Retail II
Fuente	UCI Machine Learning Repository
URL	https://archive.ics.uci.edu/dataset/502/online+retail+ii
Formato	Excel (.xlsx)
Tamaño	43,5 MB
Instancias	1.067.371 transacciones

Característica	Valor
Periodo	01/12/2009 – 09/12/2011
Licencia	CC BY 4.0

3.4 Variables del dataset

Variable	Tipo	Descripción
InvoiceNo	Nominal	Número de factura (si empieza por "C", cancelación)
StockCode	Nominal	Código del producto
Description	Texto	Nombre del producto
Quantity	Numérico	Cantidad de unidades
InvoiceDate	Fecha/Hora	Fecha y hora de la transacción
UnitPrice	Numérico	Precio unitario (£)
CustomerID	Nominal	Identificador del cliente
Country	Texto	País de residencia

4. Importación y exploración de datos

4.1 Carga del dataset

El dataset se cargó en Python usando `pandas`, unificando las dos hojas de Excel (`Year 2009–2010` y `Year 2010–2011`) en un único DataFrame.

Resultado de la carga:

- **Filas totales:** 1.067.371
- **Columnas:** 8
- **Rango temporal:** 2009-12-01 07:45 a 2011-12-09 12:50
- **Países únicos:** 43
- **Clientes únicos:** 5.942
- **Productos únicos:** 5.305

 **Figura 1:** Captura de la exploración inicial del dataset (dimensiones, tipos de datos, nulos).

```
Downloading six-1.17.0-py2.py3-none-any.whl.metadata (1.7 kB)
Downloading pandas-1.0.5-cp311-cp311-win_amd64.whl (0.8 MB)
  |#####| 9.87% 0.0 11.4 MB/s 0:00:00
Downloading openpyxl-3.1.5-py2.py3-none-any.whl (250 kB)
Downloading matplotlib-3.11.2-cp313-cp313-win_amd64.whl (9.3 MB)
  |#####| 11.1% 0.0 11.1 MB/s 0:00:00
Downloading seaborn-0.13.2-py3-none-any.whl (294 kB)
Downloading contourpy-1.4.0-cp311-cp311-win_amd64.whl (234 kB)
Downloading cyclo-0.12.1-py3-none-any.whl (8.3 kB)
Downloading fonttools-4.65.0-cp313-cp313-win_amd64.whl (2.5 MB)
  |#####| 2.97% 0.0 27.6 MB/s 0:00:00
Downloading kiwisolver-1.5.1-cp313-cp313-win_amd64.whl (70 kB)
Downloading packaging-26.3-py3-none-any.whl (129 kB)
Downloading pillow-12.3.0-cp313-cp313-win_amd64.whl (7.2 MB)
  |#####| 21.3% 0.0 21.3 MB/s 0:00:00
Downloading pyarsing-3.3.2-py3-none-any.whl (122 kB)
Downloading python-dateutil-2.9.0.post0-py2.py3-none-any.whl (229 kB)
Downloading six-1.17.0-py2.py3-none-any.whl (11 kB)
Downloading et_xmlfile-2.0.0-py3-none-any.whl (18 kB)
Downloading tzdata-2026.3-py2.py3-none-any.whl (348 kB)
Installing collected packages: tzdata, six, pyarsing, pillow, packaging, kiwisolver, fonttools, et_xmlfile, cyclo, contourpy, python-dateutil, openpyxl, pandas, matplotlib, seaborn
Successfully installed contourpy-1.4.0 cyclo-0.12.1 et_xmlfile-2.0.0 fonttools-4.65.0 kiwisolver-1.5.1 matplotlib-3.11.2 openpyxl-3.1.5 packaging-26.3 pandas-1.0.5 pillow-12.3.0 pyarsing-3.3.2 python-dateutil-2.9.0.post0 seaborn-0.13.2 six-1.17.0 tzdata-2026.3

[notice] A new release of pip is available: 25.3 -> 26.2.1
[notice] To update, run: python.exe -m pip install --upgrade pip

C:\Windows\System32>cd C:\Users\jdtgh\Documents\python analysis_retail\notebooks
C:\Users\jdtgh\Documents\python analysis_retail\notebooks>python 01_exploracion.py
Cargando hojas del Excel...

--- PRIMERAS FILAS ---
   Invoice StockCode      Description  Quantity  InvoiceDate  Price  Customer ID      Country
0  489434      85048      15CM CHRISTMAS GLASS BALL 20 LIGHTS      12  2009-12-01 07:45:00      6.95      13885.0  United Kingdom
1  489434      79323P      PINK CHERRY LIGHTS      12  2009-12-01 07:45:00      6.75      13885.0  United Kingdom
2  489434      79323M      WHITE CHERRY LIGHTS      12  2009-12-01 07:45:00      6.75      13885.0  United Kingdom
3  489434      22041      RECORD FRAME 7" SINGLE SIZE      48  2009-12-01 07:45:00      2.10      13885.0  United Kingdom
4  489434      21232      STRAWBERRY CERAMIC TRINKET BOX      24  2009-12-01 07:45:00      1.25      13885.0  United Kingdom

--- ÚLTIMAS FILAS ---
   Invoice StockCode      Description  Quantity  InvoiceDate  Price  Customer ID      Country
1867368  581587      22099      CHILDREN'S APRON DOLLY GIRL      6  2011-12-09 12:50:00      2.10      12680.0  France
1867367  581587      23254      CHILDRENS CUTLERY DOLLY GIRL      4  2011-12-09 12:50:00      4.15      12680.0  France
1867368  581587      23255      CHILDRENS CUTLERY CIRCUS PARADE      4  2011-12-09 12:50:00      4.15      12680.0  France
1867369  581587      22138      BAKING SET 9 PIECE RETROSPOT      3  2011-12-09 12:50:00      4.95      12680.0  France
1867370  581587      POST      POSTAGE      1  2011-12-09 12:50:00      18.00      12680.0  France

--- DIMENSIONES ---
Filas: 1,067,371
Columnas: 8

--- NOMBRES DE COLUMNAS ---
['Invoice', 'StockCode', 'Description', 'Quantity', 'InvoiceDate', 'Price', 'Customer ID', 'Country']

--- TIPOS DE DATOS ---
Invoice      object
StockCode    object
Description   object
Quantity      int64
InvoiceDate   datetime64[us]
Price         float64
Customer ID   float64
Country       str
dtype: object

--- INFORMACIÓN GENERAL ---
<class 'pandas.DataFrame'>
RangeIndex: 1867371 entries, 0 to 1867370
Data columns (total 8 columns):
 #   Column      Non-Null Count  Dtype
---  ---
 #   Invoice      1867371 non-null  object
 #   StockCode   1867371 non-null  object
 #   Description  1867371 non-null  object
 #   Quantity     1867371 non-null  int64
 #   InvoiceDate   1867371 non-null  datetime64[us]
 #   Price        1867371 non-null  float64
 #   Customer ID  824364 non-null   float64
 #   Country     1867371 non-null  str
dtypes: datetime64[us](1), float64(2), int64(1), object(3), str(1)
memory usage: 65.1+ MB

Administrador: Símbolo del sistema
 #   Column      Non-Null Count  Dtype
---  ---
 #   Invoice      1867371 non-null  object
 #   StockCode   1867371 non-null  object
 #   Description  1867371 non-null  object
 #   Quantity     1867371 non-null  int64
 #   InvoiceDate   1867371 non-null  datetime64[us]
 #   Price        1867371 non-null  float64
 #   Customer ID  824364 non-null   float64
 #   Country     1867371 non-null  str
dtypes: datetime64[us](1), float64(2), int64(1), object(3), str(1)
memory usage: 65.1+ MB

--- ESTADÍSTICAS DESCRIPTIVAS (numéricas) ---
   Quantity  InvoiceDate  Price  Customer ID
count  1.067371e+06      1867371  1.067371e+06  824364.000000
min      9.818000e+00      2011-01-02 21:11:55.390020  6.64030e+00  13124.630504
50%      8.899500e+04      2009-12-01 07:45:00      -5.359436e+04  12146.000000
75%      1.000000e+00      2010-07-09 09:46:00      1.250000e+00  13975.000000
max      1.000000e+00      2010-12-07 15:28:00      2.100000e+00  15255.000000
min      1.000000e+01      2011-07-22 10:23:00      4.150000e+00  16797.000000
max      8.899500e+04      2011-12-09 12:50:00      1.897000e+04  18287.000000
std      1.727050e+02      NaN      1.235531e+02  1697.464450

--- VALORES NULOS POR COLUMNA ---
Invoice      0
StockCode    0
Description   4382
Quantity      0
InvoiceDate   0
Price         0
Customer ID   243007
Country       0
dtype: int64

--- PORCENTAJE DE NULOS ---
Invoice      0.00
StockCode    0.00
Description   0.41
Quantity      0.00
InvoiceDate   0.00
Price         0.00
Customer ID   22.77
Country       0.00
dtype: float64

--- DUPLICADOS ---
filas duplicadas: 34,335



--- RANGO DE FECHAS ---
fecha mínima: 2009-12-01 07:45:00
fecha máxima: 2011-12-09 12:50:00

--- PAÍSES ÚNICOS ---
Número de países: 43
Country
United Kingdom  981330
IRE              17866
Germany          17624
France           14330
Netherlands      5160
Spain            3811
Switzerland      1189
Belgium          3123
Portugal         2620
Australia        1913
Name: count, dtype: int64

--- CLIENTES ÚNICOS ---
Clientes únicos (sin contar nulos): 5,942

--- PRODUCTOS ÚNICOS ---
Productos únicos (StockCode): 5,305

C:\Users\jdtgh\Documents\python analysis_retail\notebooks>
```



Fecha máxima: 2011-12-09 12:50:00

--- PAISES UNICOS ---

Número de países: 43

Country

United Kingdom 981330

1786

Germany 17624

France 14330

Netherlands 5160

Spain 3811

Switzerland 3189

Belgium 3123

Portugal 2620

Australia 1913

Name: count, dtype: int64

--- CLIENTES UNICOS ---

Clientes únicos (sin contar nulos): 5,942

--- PRODUCTOS UNICOS ---

Productos únicos (StockCode): 5,305

C:\Users\jdhg\Documents\python analisis_retail\notebooks\02_exploracion_avanzada.py

Cargando datos...

Total de filas originales: 1,867,371

=====

5. ANALISIS DE DUPLICADOS

Duplicados exactos (todas las columnas): 34,115

Duplicados sin considerar 'Customer ID': 34,335

--- EJEMPLOS DE FILAS DUPLICADAS (primeras 5) ---

Invoice StockCode Description Quantity InvoiceDate Price

7/9 489517 21491 SET OF THREE VINTAGE GIFT WRAPS 1 2009-12-01 11:34:00 1.95

8/1 489517 21491 SET OF THREE VINTAGE GIFT WRAPS 1 2009-12-01 11:34:00 1.95

8/5 489517 21821 GLITTER STAR GARLAND WITH BELLS 1 2009-12-01 11:34:00 3.75

8/6 489517 21821 GLITTER STAR GARLAND WITH BELLS 1 2009-12-01 11:34:00 3.75

8/1 489517 21912 VINTAGE SNAKES & LADDERS 1 2009-12-01 11:34:00 3.75

8/4 489517 21912 VINTAGE SNAKES & LADDERS 1 2009-12-01 11:34:00 3.75

8/4 489517 21912 VINTAGE SNAKES & LADDERS 1 2009-12-01 11:34:00 3.75

8/2 489517 21913 VINTAGE SEASIDE JIGSAW PUZZLES 1 2009-12-01 11:34:00 3.75

8/5 489517 21913 VINTAGE SEASIDE JIGSAW PUZZLES 1 2009-12-01 11:34:00 3.75

8/8 489517 22130 PARTY CONE CHRISTMAS DECORATION 6 2009-12-01 11:34:00 0.85

Duplicados con Customer ID nulo: 15,702

Duplicados con Customer ID presente: 51,548

Duplicados con Quantity negativo: 902

Duplicados con Price negativo: 0

=====

6. GENERANDO VISUALIZACIONES

Guardado: 01_histogramas_quantity_price.png

C:\Users\jdhg\Documents\python analisis_retail\notebooks\02_exploracion_avanzada.py:100: MatplotlibDeprecationWarning: vert: bool was deprecated in Matplotlib 3.11 and will be removed in 3.13. Use orientation: ('vertical', 'horizontal') instead.


axes[0].boxplot(df['Quantity'], vert=True, patch_artist=True,

C:\Users\jdhg\Documents\python analisis_retail\notebooks\02_exploracion_avanzada.py:106: MatplotlibDeprecationWarning: vert: bool was deprecated in Matplotlib 3.11 and will be removed in 3.13. Use orientation: ('vertical', 'horizontal') instead.

axes[1].boxplot(df['Price'], vert=True, patch_artist=True,

Guardado: 02_boxplots_quantity_price.png

Guardado: 03_top_paises.png



Fecha máxima: 2011-12-09 12:50:00

--- PAISES UNICOS ---

Número de países: 43

Country

United Kingdom 981330

1786

Germany 17624

France 14330

Netherlands 5160

Spain 3811

Switzerland 3189

Belgium 3123

Portugal 2620

Australia 1913

Name: count, dtype: int64

--- CLIENTES UNICOS ---

Clientes únicos (sin contar nulos): 5,942

--- PRODUCTOS UNICOS ---

Productos únicos (StockCode): 5,305

C:\Users\jdhg\Documents\python analisis_retail\notebooks\02_exploracion_avanzada.py

Cargando datos...

Total de filas originales: 1,867,371

=====

5. ANALISIS DE DUPLICADOS

Duplicados exactos (todas las columnas): 34,115

Duplicados sin considerar 'Customer ID': 34,335

--- EJEMPLOS DE FILAS DUPLICADAS (primeras 5) ---

Invoice StockCode Description Quantity InvoiceDate Price

7/9 489517 21491 SET OF THREE VINTAGE GIFT WRAPS 1 2009-12-01 11:34:00 1.95

8/1 489517 21491 SET OF THREE VINTAGE GIFT WRAPS 1 2009-12-01 11:34:00 1.95

8/5 489517 21821 GLITTER STAR GARLAND WITH BELLS 1 2009-12-01 11:34:00 3.75

8/6 489517 21821 GLITTER STAR GARLAND WITH BELLS 1 2009-12-01 11:34:00 3.75

8/1 489517 21912 VINTAGE SNAKES & LADDERS 1 2009-12-01 11:34:00 3.75

8/4 489517 21912 VINTAGE SNAKES & LADDERS 1 2009-12-01 11:34:00 3.75

8/4 489517 21912 VINTAGE SNAKES & LADDERS 1 2009-12-01 11:34:00 3.75

8/2 489517 21913 VINTAGE SEASIDE JIGSAW PUZZLES 1 2009-12-01 11:34:00 3.75

8/5 489517 21913 VINTAGE SEASIDE JIGSAW PUZZLES 1 2009-12-01 11:34:00 3.75

8/8 489517 22130 PARTY CONE CHRISTMAS DECORATION 6 2009-12-01 11:34:00 0.85

Duplicados con Customer ID nulo: 15,702

Duplicados con Customer ID presente: 51,548

Duplicados con Quantity negativo: 902

Duplicados con Price negativo: 0

=====

6. GENERANDO VISUALIZACIONES

Guardado: 01_histogramas_quantity_price.png

C:\Users\jdhg\Documents\python analisis_retail\notebooks\02_exploracion_avanzada.py:100: MatplotlibDeprecationWarning: vert: bool was deprecated in Matplotlib 3.11 and will be removed in 3.13. Use orientation: ('vertical', 'horizontal') instead.


axes[0].boxplot(df['Quantity'], vert=True, patch_artist=True,



C:\Users\jdhg\Documents\python analisis_retail\notebooks\02_exploracion_avanzada.py:106: MatplotlibDeprecationWarning: vert: bool was deprecated in Matplotlib 3.11 and will be removed in 3.13. Use orientation: ('vertical', 'horizontal') instead.

axes[1].boxplot(df['Price'], vert=True, patch_artist=True,

Guardado: 02_boxplots_quantity_price.png

Guardado: 03_top_paises.png






```
total de filas originales: 1,007,371

=====
3. ANÁLISIS DE DUPLICADOS
=====

duplicados exactos (todas las columnas): 34,335
duplicados sin considerar 'customer ID': 34,335

--- EJEMPLOS DE FILAS DUPLICADAS (primeras 5) ---
Invoice StockCode Description Quantity InvoiceDate Price Customer ID Country
79 489517 21491 SET OF THREE VINTAGE GIFT WRAPS 1 2009-12-01 11:34:00 1.95 16329.0 United Kingdom
91 489517 21491 SET OF THREE VINTAGE GIFT WRAPS 1 2009-12-01 11:34:00 1.95 16329.0 United Kingdom
80 489517 21821 GILFIER STAR GARLAND WITH BELLS 1 2009-12-01 11:34:00 3.75 16329.0 United Kingdom
88 489517 21821 GILFIER STAR GARLAND WITH BELLS 1 2009-12-01 11:34:00 3.75 16329.0 United Kingdom
63 489517 21912 VINTAGE SNAKES & LADDERS 1 2009-12-01 11:34:00 3.75 16329.0 United Kingdom
71 489517 21912 VINTAGE SNAKES & LADDERS 1 2009-12-01 11:34:00 3.75 16329.0 United Kingdom
94 489517 21912 VINTAGE SNAKES & LADDERS 1 2009-12-01 11:34:00 3.75 16329.0 United Kingdom
62 489517 21913 VINTAGE SEASIDE JIGSAW PUZZLES 1 2009-12-01 11:34:00 3.75 16329.0 United Kingdom
89 489517 21913 VINTAGE SEASIDE JIGSAW PUZZLES 1 2009-12-01 11:34:00 3.75 16329.0 United Kingdom
88 489517 22130 PARTY CODE CHRISTMAS DECORATION 6 2009-12-01 11:34:00 0.85 16329.0 United Kingdom

duplicados con Customer ID nulo: 15,702
duplicados con Customer ID presente: 51,548
duplicados con Quantity negativa: 902
duplicados con Price negativo: 0

=====
4. GENERANDO VISUALIZACIONES
=====

Guardado: 01_histogramas_quantity_price.png
/Users/jdthg/Documents/python analisis_retail/notebooks/02_exploracion_avanzada.py:100: MatplotlibDeprecationWarning: vert: bool was deprecated in Matplotlib 3.11 and will be removed in 3.13. Use orientation: ('vertical', 'horizontal') instead.
/Users/jdthg/Documents/python analisis_retail/notebooks/02_exploracion_avanzada.py:106: MatplotlibDeprecationWarning: vert: bool was deprecated in Matplotlib 3.11 and will be removed in 3.13. Use orientation: ('vertical', 'horizontal') instead.
Guardado: 02_boxplots_quantity_price.png
Guardado: 03_top_paises.png
Guardado: 04_top_productos.png
Guardado: 05_evolucion_mensual.png
Guardado: 06_transacciones_por_hora.png

=====
5. VALORES NEGATIVOS Y OUTLIERS
=====

Transacciones con Quantity < 0: 22,950 (2.15%)
transacciones con Invoice empezando por 'C': 19,694

Outliers en Quantity (IQR): 116,489 (10.91%)
Límite inferior: -12.50, Límite superior: 23.50

Outliers en Price (IQR): 68,105 (6.38%)
Límite inferior: -3.10, Límite superior: 8.50

=====
6. GUARDANDO RESULTADOS
=====

Métrica Valor
Filas totales 1067371
Duplicados exactos 34335
Duplicados sin Customer ID 34335
Nulos en Customer ID 248807
Nulos en Description 4382
Quantity < 0 22950
Invoice empieza por 'C' 19694
Outliers Quantity (IQR) 116489
Outliers Price (IQR) 68105
Clientes únicos 5942
Productos únicos 5305
Países únicos 43

Análisis completado. Revisa salidas/figuras/ y salidas/tablas/

/Users/jdthg/Documents/python analisis_retail/notebooks
/Users/jdthg/Documents/python analisis_retail/notebooks
```

4.2 Estadísticas descriptivas iniciales

Estadístico	Quantity	UnitPrice	CustomerID
Media	9,94	4,64	15.324,64
Estadístico	Quantity	UnitPrice	CustomerID
Mediana	3,00	2,10	15.252,00
Moda	1	1,25	—
Desv. estándar	172,79	123,55	1.697,46
Mínimo	-80.995	-53.594,36	12.346,00
Máximo	80.995	38.970,00	18.287,00

Interpretación:

- La **media de Quantity (9,94)** muy superior a la **mediana (3)** indica una distribución **asimétrica a la derecha**.
- Los **valores negativos** en Quantity y UnitPrice corresponden a **cancelaciones y devoluciones**.
- El **CustomerID está codificado como float64**, cuando debería ser entero.

4.3 Valores nulos

Variable	Nulos	Porcentaje
InvoiceNo	0	0,00%

StockCode	0	0,00%
Description	4.382	0,41%
Quantity	0	0,00%
InvoiceDate	0	0,00%
UnitPrice	0	0,00%
CustomerID	243.007	22,77%
Country	0	0,00%

Hallazgo clave: el 22,77% de las transacciones no tienen CustomerID, lo que obliga a **separar el dataset en dos versiones:** una completa (para análisis general) y otra filtrada (para RFM).

4.4 Duplicados

Se detectaron **34.335 filas duplicadas** (3,22%). Análisis detallado:

- 15.702 duplicados con CustomerID nulo.
- ♦ 15.540 duplicados con CustomerID presente.
- 902 duplicados con Quantity negativa.
- 0 duplicados con UnitPrice negativo.

Conclusión: tras revisar ejemplos concretos, la mayoría son **compras repetidas legítimas** del mismo producto en la misma factura, no errores de captura. **Decisión:** agregar (sumar Quantity) en lugar de eliminar.

4.5 Distribución geográfica

Top 5 países por número de transacciones:

País	Transacciones
United Kingdom	981.330
EIRE (Irlanda)	17.866
Germany	17.624
France	14.330
Netherlands	5.140

Interpretación: el Reino Unido concentra el **91,9%** de las transacciones. La tienda es principalmente británica.

5. Limpieza y preparación de datos

5.1 Pasos de limpieza aplicados

#	Paso	Filas antes	Filas después	Eliminadas	%	Motivo
1	Agregación de duplicados	1.067.371	1.022.443	44.928	4,21%	Compras repetidas del mismo producto
2	Eliminación de cancelaciones	1.022.443	1.000.009	22.434	2,19%	Invoice 'C' o Quantity negativa
3	Eliminación de precios ≤ 0	1.000.009	997.393	2.616	0,26%	Precio inválido
4	Eliminación de Description nula	997.393	997.393	0	0,00%	Ya no había nulos
5	Eliminación de outliers extremos (P99.9)	997.393	995.416	1.977	0,20%	Valores extremos

Total: 71.955 filas eliminadas (6,74% del dataset original).

 **Figura 2:** Gráfico de barras mostrando las filas eliminadas en cada paso de la limpieza.

```
Matrica Valor
Filas totales 1867371
Duplicados exactos 34335
Duplicados sin Customer ID 14335
Nulos en Customer ID 249007
Nulos en Description 4382
Quantity < 0 22958
Invoice empleza por t 18684
Outliers Quantity (IQR) 116489
Outliers Price (IQR) 68185
Clientes Unicos 5942
Productos Unicos 5305
Países Unicos 43
```

✓ Analisis completado. Revisa salidas/figuras/ y salidas/tablas/

```
~\Users\jdtg\Documents\python analisis_retail\notebooks>
~\Users\jdtg\Documents\python analisis_retail\notebooks>df_limpio = df.groupby([...]).agg({'Quantity': 'sum'})
df_limpio no se reconoce como un comando interno o externo,
programa o archivo por lotes ejecutable.
```

```
~\Users\jdtg\Documents\python analisis_retail\notebooks>python 01_limieza.py
python: can't open file 'C:\Users\jdtg\Documents\python analisis_retail\notebooks\01_limieza.py': [Errno 2] No such file or directory
~\Users\jdtg\Documents\python analisis_retail\notebooks>python 03_limieza.py
```

1. CARGANDO DATOS

```
filas iniciales: 1,867,371
columnas iniciales: ['Invoice', 'StockCode', 'Description', 'Quantity', 'InvoiceDate', 'Price', 'Customer ID', 'Country']
```

2. TRATAMIENTO DE DUPLICADOS

```
✓ Agregación de duplicados (suma de Quantity)
Antes: 1,867,371 | Después: 1,822,443 | Eliminadas: 44,928
```

3. ELIMINACIÓN DE CANCELACIONES

```
✓ Eliminación de cancelaciones
Antes: 1,822,443 | Después: 1,800,009 | Eliminadas: 22,434
```

4. ELIMINACIÓN DE PRECIOS INVÁLIDOS

```
✓ Eliminación de precios <= 0
Antes: 1,800,009 | Después: 997,393 | Eliminadas: 2,616
```

5. TRATAMIENTO DE DESCRIPTION NULOS

```
nulos en Description antes: 0
```

```
✓ Eliminación de filas con Description nula
Antes: 997,393 | Después: 997,393 | Eliminadas: 0
```

6. TRATAMIENTO DE OUTLIERS EXTREMOS

```
percentil 99.9 de Quantity: 500
percentil 99.9 de UnitPrice: 162.64
```

```
✓ Eliminación de outliers extremos (percentil 99.9)
Antes: 997,393 | Después: 995,416 | Eliminadas: 1,977
```

7. CONVERSIÓN DE TIPOS

```
tipos tras la conversión:
Invoice      str
StockCode    str
```

```
~\Users\jdtg\Documents\python analisis_retail\notebooks>python 01_limieza.py
python: can't open file 'C:\Users\jdtg\Documents\python analisis_retail\notebooks\01_limieza.py': [Errno 2] No such file or directory
~\Users\jdtg\Documents\python analisis_retail\notebooks>python 03_limieza.py
```

1. CARGANDO DATOS

```
filas iniciales: 1,867,371
columnas iniciales: ['Invoice', 'StockCode', 'Description', 'Quantity', 'InvoiceDate', 'Price', 'Customer ID', 'Country']
```

2. TRATAMIENTO DE DUPLICADOS

```
✓ Agregación de duplicados (suma de Quantity)
Antes: 1,867,371 | Después: 1,822,443 | Eliminadas: 44,928
```

3. ELIMINACIÓN DE CANCELACIONES

```
✓ Eliminación de cancelaciones
Antes: 1,822,443 | Después: 1,800,009 | Eliminadas: 22,434
```

4. ELIMINACIÓN DE PRECIOS INVÁLIDOS

```
✓ Eliminación de precios <= 0
Antes: 1,800,009 | Después: 997,393 | Eliminadas: 2,616
```

5. TRATAMIENTO DE DESCRIPTION NULOS

```
nulos en Description antes: 0
```

```
✓ Eliminación de filas con Description nula
Antes: 997,393 | Después: 997,393 | Eliminadas: 0
```

6. TRATAMIENTO DE OUTLIERS EXTREMOS

```
Percentil 99.9 de Quantity: 500
Percentil 99.9 de UnitPrice: 162.64
```

```
✓ Eliminación de outliers extremos (percentil 99.9)
Antes: 997,393 | Después: 995,416 | Eliminadas: 1,977
```

7. CONVERSIÓN DE TIPOS

```
Tipos tras la conversión:
```

```
Invoice      str
```

```
StockCode    str
```

```
Description  object
```

```
InvoiceDate  datetime64[ns]
```

```
UnitPrice    float64
```

```
CustomerID   int64
```

```
Country      category
```

```
Quantity     int64
```

```
dtype: object
```

8. CREACIÓN DE VARIABLES DERIVADAS

Variables creadas:

```
TotalPrice Year Month Hour DayName YearMonth
```


```
0 30.8 2009 12 7 Hartes 2009-12
```

```
1 30.5 2009 12 7 Hartes 2009-12
```

```
2 30.8 2009 12 7 Hartes 2009-12
```

```
3 180.8 2009 12 7 Hartes 2009-12
```

```
4 30.6 2009 12 7 Hartes 2009-12
```



```

9. SEPARACIÓN DE DATASETS
=====
Dataset COMPLETO: 995,416 filas
Dataset RFM (con CustomerID): 767,853 filas
Clientes únicos en RFM: 5,852

10. VALIDACIÓN FINAL
=====

Dimensiones finales (df_completo): (995416, 18)
Dimensiones finales (df_rfm): (767853, 18)

--- Estadísticas descriptivas finales ---

```

	Quantity	UnitPrice	TotalPrice
count	995416.000000	995416.000000	995416.000000
mean	18.847567	3.446272	19.226520
std	24.349756	4.841000	51.156156
min	1.000000	0.001000	0.001000
25%	1.000000	1.250000	4.200000
50%	4.000000	2.100000	10.200000
75%	12.000000	4.150000	17.700000
max	500.000000	162.600000	4707.300000

```

--- Nulos restantes ---
InvoiceNo      0
StockCode      0
Description    0
InvoiceDate    0
UnitPrice      0
CustomerID     227563
Country        0
Quantity       0
TotalPrice     0
Year           0
Month          0
Day            0
DayOfWeek      0
Quarter        0
YearMonth      0
DayName        0
Isleekend      0
dtypes: int64

--- Rango temporal ---
Fecha mínima: 2009-12-01 07:45:00
Fecha máxima: 2011-12-09 12:50:00

--- Valores negativos restantes ---
Quantity < 0: 0
UnitPrice < 0: 0
TotalPrice < 0: 0

11. VISUALIZACIÓN DEL PROCESO DE LIMPIEZA
=====

```

	Peso	Filas antes	Filas después	Filas eliminadas	% eliminado	Activo
Agregación de duplicados (suma de Quantity)	1867771	1822443	44928	4.21	Compras repetidas del mismo producto en la misma factura	
Eliminación de cancelaciones	1022443	1000009	22434	2.19	InvoiceNo empieza por "C" o Quantity negativa	
Eliminación de precios <= 0	1000009	997393	2616	0.26	Precio negativo o cero	
Eliminación de filas con Description nula	997393	997393	0	0.00	Bajo porcentaje (0.41%) y sin valor para el análisis	
Eliminación de outliers extremos (percentil 99.9)	997393	995416	1977	0.20	Valores extremos que distorsionan el análisis	

```

Guardado: 07_proceso_limpieza.png

12. EXPORTANDO DATASETS LIMPÍOS
=====
Guardado: datos_limpios/online_retail_completo.csv (995,416 filas)
Guardado: datos_limpios/online_retail_rfm.csv (767,853 filas)
Traceback (most recent call last):
  File "C:\Users\jdtg\Documents\python analisis_retail\notebooks\03_limpieza.py", line 294, in <module>
    df_completo.to_parquet(RUTA_LIMPÍO / "online_retail_completo.parquet", index=False)
  File "C:\Users\jdtg\AppData\Local\Programs\Python\Python313\Lib\site-packages\pandas\core\frame.py", line 3135, in to_parquet
    df_completo.to_parquet(RUTA_LIMPÍO / "online_retail_completo.parquet", index=False)
  File "C:\Users\jdtg\AppData\Local\Programs\Python\Python313\Lib\site-packages\pandas\core\frame.py", line 3135, in to_parquet
    return to_parquet(
           ^^^^^^^^^
           ~~~~~
    ...<7 lines>...
           ~~~~~
           ^^^^^^^^^
    )
  File "C:\Users\jdtg\AppData\Local\Programs\Python\Python313\Lib\site-packages\pandas\io\parquet.py", line 486, in to_parquet
    impl = get_engine(engine)
  File "C:\Users\jdtg\AppData\Local\Programs\Python\Python313\Lib\site-packages\pandas\io\parquet.py", line 68, in get_engine
    raise ImportError(
    ...<7 lines>...
    )
ImportError: Unable to find a usable engine; tried using: 'pyarrow', 'fastparquet'.
A suitable version of pyarrow or fastparquet is required for parquet support.
Trying to import the above resulted in these errors:
- 'Import pyarrow' failed: pyarrow is required for parquet support. Use pip or conda to install the pyarrow package.
- 'Import fastparquet' failed: fastparquet is required for parquet support. Use pip or conda to install the fastparquet package.

C:\Users\jdtg\Documents\python analisis_retail\notebooks>

```

5.2 Variables derivadas creadas

Variable	Descripción
TotalPrice	Quantity × UnitPrice
Year	Año de la transacción
Month	Mes (1–12)
Day	Día del mes
Hour	Hora del día
DayOfWeek	Día de la semana (0 = lunes)
DayName	Nombre del día en español
Quarter	Trimestre (1–4)
YearMonth	Año-Mes (formato YYYY-MM)
IsWeekend	Booleano: sábado o domingo

5.3 Conversión de tipos

Variable	Tipo original	Tipo final
CustomerID	float64	Int64
InvoiceNo	object	str
StockCode	object	str
Country	object	category

5.4 Datasets finales

Dataset	Filas	Columnas	Uso
df_completo	995.416	18	Análisis general de ventas
df_rfm	767.853	18	Segmentación RFM (5.852 clientes)

5.5 Validación final

- ✔ **0 valores negativos** en Quantity, UnitPrice o TotalPrice.
- ✔ **Todos los nulos restantes** (227.563) están únicamente en CustomerID.
- ✔ **Rango temporal** preservado: 2009-12-01 a 2011-12-09.

5.6 Estadísticas descriptivas finales

Estadístico	Quantity	UnitPrice	TotalPrice
Media	10,04	3,44	19,22
Mediana	3,00	2,10	10,20
Moda	1	1,25	—
Desv. estándar	24,34	4,84	51,15
Mínimo	1	0,001	0,001
Máximo	500	162,60	4.707,36


6. Análisis Exploratorio de Datos (EDA)

6.1 Análisis de correlaciones

Matriz de correlación de Pearson entre variables numéricas:

Par de variables	Coefficiente
Quantity ↔ TotalPrice	0,632
UnitPrice ↔ TotalPrice	0,125
Quantity ↔ UnitPrice	-0,131

Figura 3: Heatmap de correlación entre Quantity, UnitPrice y TotalPrice.




Interpretación: el ingreso por transacción depende **más del volumen que del precio**. La correlación negativa débil entre cantidad y precio sugiere que los productos más caros se venden en menores cantidades.

6.2 Análisis temporal

Ingresos mensuales

Figura 4: Serie temporal de ingresos mensuales (2009–2011).



Hallazgos:

- **Pico máximo en noviembre 2010:** ~1,46 M€.
- **Pico secundario en noviembre 2011:** ~1,40 M€.
- **Valles profundos en enero-febrero** de cada año (~500.000 £).
- **Estacionalidad clara:** campaña navideña concentra los mayores ingresos.

Ingresos por día de la semana

Figura 5: Ingresos por día de la semana.

totalPrice < 0: 0

11. VISUALIZACIÓN DEL PROCESO DE LIMPIEZA

	Paso	Filas antes	Filas después	Filas eliminadas	% eliminado	Motivo
Agregación de duplicados (suma de Quantity)		1867371	1822443	44928	4.21	Compras repetidas del mismo producto en la misma factura
	Eliminación de cancelaciones	1822443	1000009	22434	2.19	InvoiceNo empieza por "C" o Quantity negative
	Eliminación de precios <= 0	1000009	997393	2616	0.26	Precio negativo o cero
Eliminación de filas con Description nula		997393	997393	0	0.00	Bajo porcentaje (0.41%) y sin valor para el análisis
Eliminación de outliers extremos (percentil 99.9)		997393	995416	1977	0.20	Valores extremos que distorsionan el análisis

Guardado: 07_proceso_limpieza.png

12. EXPORTANDO DATASETS LIMPIOS

Guardado: datos_limpios/online_retail_completo.csv (995,416 filas)

Guardado: datos_limpios/online_retail_rfm.csv (767,853 filas)

Traceback (most recent call last):

File "C:\Users\jdtg\Documents\python analisis_retail\notebooks\03_limpieza.py", line 294, in <module>
df_completo.to_parquet(RUTA_LIMPIO / "online_retail_completo.parquet", index=False)

File "C:\Users\jdtg\AppData\Local\Programs\Python\Python313\Lib\site-packages\pandas\core\frame.py", line 3135, in to_parquet
return to_parquet(

self,

...<7 lines>...

**kwargs,

)

File "C:\Users\jdtg\AppData\Local\Programs\Python\Python313\Lib\site-packages\pandas\io\parquet.py", line 486, in to_parquet
impl = get_engine(engine)

File "C:\Users\jdtg\AppData\Local\Programs\Python\Python313\Lib\site-packages\pandas\io\parquet.py", line 68, in get_engine
raise ImportError(

...<7 lines>...

)

ImportError: Unable to find a usable engine; tried using: 'pyarrow', 'fastparquet'.

A suitable version of pyarrow or fastparquet is required for parquet support.

Falling back to using the default engine: pandas.

Trying to import the above resulted in these errors:

- Import pyarrow failed. pyarrow is required for parquet support. Use pip or conda to install the pyarrow

- Import fastparquet failed. fastparquet is required for parquet support. Use pip or conda to install the

C:\Users\jdtg\Documents\python analisis_retail\notebooks>pip install pyarrow

Collecting pyarrow

Downloading pyarrow-25.0.1-cp13-cp13-win_amd64.whl (27.9 MB)

Downloading pyarrow-25.0.1-cp13-cp13-win_amd64.whl (27.9 MB)

Installing collected packages: pyarrow

Successfully installed pyarrow-25.0.1

[notice] A new release of pip is available: 25.1 -> 26.2.1

[notice] To update, run: python.exe -m pip install --upgrade pip

C:\Users\jdtg\Documents\python analisis_retail\notebooks>python 04_eda.py

1. CARGANDO DATOS LIMPIOS

Filas: 995,416

Columnas: 18

Rango temporal: 2009-12-01 07:45:00 - 2011-12-09 12:50:00

2. MATRIZ DE CORRELACIÓN

Matriz de correlación (Pearson):

Quantity UnitPrice TotalPrice

Quantity 1.000 -0.131 0.632


UnitPrice -0.131 1.000 0.125

TotalPrice 0.632 0.125 1.000

Guardado: 08_correlacion_heatmap.png

3. ANÁLISIS TEMPORAL


Guardado: 09_ingresos_mensuales.png



Día	Ingresos (£)
Jueves	~3.900.000
Martes	~3.700.000
Miércoles	~3.400.000
Lunes	~3.300.000
Viernes	~2.900.000
Domingo	~1.800.000
Sábado	0 (cerrado)

Ingresos por hora

 **Figura 6:** Ingresos por hora del día.



- Mayor facturación entre **10:00 y 15:00**.
- **Pico máximo a las 12:00** (~2,75 M£).
- Actividad nula antes de las 6:00 y después de las 20:00.


6.3 Análisis geográfico

Top 10 países por ingresos:

País	Ingresos (£)
United Kingdom	16.248.567
EIRE (Irlanda)	632.305

Netherlands	532.131
Germany	425.768
France	328.482
Australia	163.146
Spain	101.860
Switzerland	100.161
Sweden	83.162
Belgium	64.045

 **Figura 7:** Top 10 países por ingresos.



 **Figura 8:** Top 10 países excluyendo Reino Unido.

```
File "C:\Users\jdtgh\AppData\Local\Programs\Python\Python313\Lib\site-packages\pandas\core\frame.py", line 3135, in to_parquet
    return to_parquet(
           ^^^^^^^^^
           self,
           ...-G lines...
           *kwargs,
           )
File "C:\Users\jdtgh\AppData\Local\Programs\Python\Python313\Lib\site-packages\pandas\io\parquet.py", line 486, in to_parquet
    impl = get_engine(engine)
File "C:\Users\jdtgh\AppData\Local\Programs\Python\Python313\Lib\site-packages\pandas\io\parquet.py", line 68, in get_engine
    raise ImportError(
           ^^^^^^^^^
           ...-G lines...
           )
ImportError: Unable to find a usable engine; tried using: 'pyarrow', 'fastparquet'.
A suitable version of pyarrow or fastparquet is required for parquet support.
Trying to import the above resulted in these errors:
- Import pyarrow failed. pyarrow is required for parquet support. Use pip or conda to install the pyarrow package.
- Import fastparquet failed. fastparquet is required for parquet support. Use pip or conda to install the fastparquet package.

C:\Users\jdtgh\Documents\python analisis_retail\notebooks>pip install pyarrow
Collecting pyarrow
  Downloading pyarrow-25.0.1-cp313-cp313-win_amd64.whl.metadata (3.0 kB)
  Downloading pyarrow-25.0.1-cp313-cp313-win_amd64.whl (27.9 MB)
----- 27.9/27.9 MB 18.9 MB/s 0:00:01
Installing collected packages: pyarrow
Successfully installed pyarrow-25.0.1


[notice] A new release of pip is available: 25.3 -> 26.2.1
[notice] To update, run: python.exe -m pip install --upgrade pip

C:\Users\jdtgh\Documents\python analisis_retail\notebooks>python 04_eda.py
=====
1. CARGANDO DATOS LIMPITOS
Filas: 995,416
Columnas: 18
Rango Temporal: 2009-12-01 07:45:00 + 2011-12-09 12:58:00

=====
2. MATRIZ DE CORRELACIÓN
Matriz de correlación (Pearson):
      Quantity  UnitPrice  TotalPrice
Quantity    1.000    -0.131    0.632
UnitPrice   -0.131    1.000    0.125
TotalPrice   0.632    0.125    1.000
Guardado: 08_correlacion_heatmap.png

=====
3. ANALISIS TEMPORAL
Guardado: 09_ingresos_mensuales.png
Guardado: 10_ingresos_por_dia.png
Guardado: 11_ingresos_por_hora.png

=====
4. ANALISIS GEOGRÁFICO
Top 10 países por ingresos:
Country      Ingresos
United Kingdom  16248567.29
EIRE           632395.26
Netherlands    512138.94
Germany        425767.11
France         328481.76
Australia      161146.22
Spain          101859.62
Switzerland    100161.29
Sweden         83162.44
Belgium        64084.77
name: TotalPrice, dtype: float64
Guardado: 12_top_paises_ingresos.png
```



Ticket medio por país (Top 10):

País	Media (£)	Mediana (£)
Netherlands	105,27	69,60
Australia	91,91	35,40
Japan	70,36	55,20
Sweden	63,43	22,50
Denmark	50,78	24,96
Lithuania	42,56	30,00
Hong Kong	40,84	23,40
Thailand	40,40	15,60
Singapore	40,00	30,00
EIRE	36,97	17,70

Conclusión: UK domina en volumen, pero Países Bajos y Australia tienen el ticket medio más alto.

6.4 Análisis de productos

Top 10 productos por ingresos:

Producto	Ingresos (£)
REGENCY CAKESTAND 3 TIER	344.563
WHITE HANGING HEART T-LIGHT HOLDER	240.115
PARTY BUNTING	149.187
JUMBO BAG RED RETROSPOT	143.066
POSTAGE	112.154
ASSORTED COLOUR BIRD ORNAMENT	111.774
PAPER CHAIN KIT 50'S CHRISTMAS	100.592
CHILLI LIGHTS	85.489
JUMBO BAG STRAWBERRY	67.007
HOT WATER BOTTLE TEA AND SYMPATHY	63.518

 **Figura 9:** Top 10 productos por ingresos.

```
C:\Users\jdtth\Documents\python_analisis_retail\notebooks>pip install pyarrow
Collecting pyarrow
  Downloading pyarrow-25.0.1-cp313-cp313-win_amd64.whl.metadata (3.0 kB)
  Downloading pyarrow-25.0.1-cp313-cp313-win_amd64.whl (27.9 MB)
----- 27.9/27.9 MB 18.9 MB/s 0:00:01
Installing collected packages: pyarrow
Successfully installed pyarrow-25.0.1

[notice] A new release of pip is available: 25.3 -> 26.2.1
[notice] To update, run: python.exe -m pip install --upgrade pip


C:\Users\jdtth\Documents\python_analisis_retail\notebooks>python 04_cda.py
=====
1. CARGANDO DATOS LIMPLOS
=====
Filas: 995,416
Columnas: 18
Rango temporal: 2009-12-01 07:45:00 -> 2011-12-09 12:50:00

=====
2. MATRIZ DE CORRELACIÓN
=====
Matriz de correlación (Pearson):
      Quantity  UnitPrice  TotalPrice
Quantity    1.000    -0.131     0.632
UnitPrice   -0.131     1.000     0.125
TotalPrice   0.632     0.125     1.000
Guardado: 08_correlacion_heatmap.png

=====
3. ANALISIS TEMPORAL
=====
Guardado: 09_ingresos_mensuales.png
Guardado: 10_ingresos_por_dia.png
Guardado: 11_ingresos_por_hora.png

=====
4. ANALISIS GEOGRAFICO
=====
Top 10 países por ingresos:
Country
United Kingdom    16248567.29
USA                632309.26
Netherlands       532130.94
Germany           425767.11
France            328481.76
Australia         163146.22
Spain             101859.62
Netherlands       100161.29
Sweden            83162.44
Belgium           64064.77
name: TotalPrice, dtype: float64
Guardado: 12_top_paises_ingresos.png
Guardado: 13_top_paises_no_uk.png

=====
5. ANALISIS DE PRODUCTOS
=====
Top 10 productos por ingresos:
description
REGENCY CAKESTAND 3 TIER          344563.25
WHITE HANGING HEART T-LIGHT HOLDER 240115.01
PARTY BUNTING                   149187.49
JUMBO BAG RED RETROSPOT          143065.56
POSTAGE                          112153.85
ASSORTED COLOUR BIRD ORNAMENT    111774.82
PAPER CHAIN KIT 50'S CHRISTMAS   100591.69
CHILLI LIGHTS                    85489.91
JUMBO BAG STRAWBERRY             67006.89
HOT WATER BOTTLE TEA AND SYMPATHY 53517.75
name: TotalPrice, dtype: float64
```



Hallazgo: los productos más rentables **no coinciden** con los más vendidos por cantidad. Dominan artículos de decoración y regalo.

6.5 Análisis de clientes

Top 10 clientes por número de pedidos:

CustomerID	Nº Pedidos
14911	381
12748	330
17841	211
15311	208
13089	203

Top 10 clientes por ingresos:

CustomerID	Ingresos (£)
14646	507.320
18102	502.933
14156	298.240
14911	284.055
13694	190.862

Conclusión: alta concentración de ingresos en pocos clientes (patrón B2B).

6.6 Resumen del EDA

Métrica	Valor
Ingresos totales	£19.138.385,60
Ingreso medio por transacción	£19,23
Ingreso mediano por transacción	£10,20
Nº de pedidos únicos	39.631
Nº de clientes únicos	5.852
Nº de productos únicos	4.913
País con más ingresos	United Kingdom
Mes con más ingresos	Noviembre
Día con más ingresos	Jueves

7. Segmentación RFM de clientes

7.1 Metodología

Se aplicó el análisis RFM a los **5.852 clientes** con identificador único:

- **Recencia (R):** días desde la última compra (fecha de referencia: 10/12/2011).
- **Frecuencia (F):** número de facturas únicas.
- **Monetario (M):** suma total del gasto (£).

Cada métrica se puntuó del **1 al 5** usando cuantiles (5 = mejor), y los clientes se agruparon en **6 segmentos de negocio**.

7.2 Estadísticas RFM

Métrica	Media	Mediana	Mínimo	Máximo
Recencia (días)	201,17	96	1	739
Frecuencia	6,26	3	1	381
Monetario (£)	2.808,96	880,38	2,90	507.320,36

7.3 Distribución de segmentos

 **Figura 10:** Distribución de clientes por segmento.

```
(Notice) To update, run: python.exe -m pip install --upgrade pip
C:\Users\jdtgh\Documents\python analisis_retail\notebooks>python 04_edu.py

=====
1. CARGANDO DATOS LIMPIOS
=====
Filas: 995,416
Columnas: 18
Rango temporal: 2009-12-01 07:45:00 -> 2011-12-09 12:50:00

=====
2. MATRIZ DE CORRELACIÓN
=====
Matriz de correlación (Pearson):
      Quantity  UnitPrice  TotalPrice
Quantity    1.000    -0.131    0.632
UnitPrice   -0.131    1.000    0.125
TotalPrice   0.632    0.125    1.000
Guardado: 08_correlacion_heatmap.png

=====
3. ANÁLISIS TEMPORAL
=====
Guardado: 09_ingresos_mensuales.png
Guardado: 10_ingresos_por_dia.png
Guardado: 11_ingresos_por_hora.png

=====
4. ANÁLISIS GEOGRÁFICO
=====
Top 10 países por ingresos:
Country
United Kingdom    16248567.29
ETRE               632305.26
Netherlands       532130.94
Germany           425767.11
France            328481.76
Australia         163146.22
Spain             101859.62
Switzerland       100161.29
Sweden            93162.44
Belgium           64844.77
Name: TotalPrice, dtype: float64
Guardado: 12_top_paises_ingresos.png
Guardado: 13_top_paises_no_uk.png

=====
5. ANÁLISIS DE PRODUCTOS
=====
Top 10 productos por ingresos:
Description
REGENCY CAKESTAND 3 TIER    344563.25
WHITE HANGING HEART T-LIGHT HOLDER    248115.01
PARITY BUNTING            149187.05
TUMBO BAG RED RETROSPOT    143065.56
POSTAGE                    112153.85
ASSORTED COLOUR BIRD ORNAMENT    111774.32
PAPER CHAIN KIT 50'S CHRISTMAS    100591.69
CHILLI LIGHTS              85489.91
TUMBO BAG STRAWBERRY       67006.89
HOT WATER BOTTLE TEA AND SYMPATHY    63517.75
Name: TotalPrice, dtype: float64
Guardado: 14_top_productos_ingresos.png
Guardado: 15_dispersion_quantity_totalprice.png
Guardado: 16_dispersion_unitprice_totalprice.png

=====
6. ANÁLISIS POR SEGMENTOS
=====
Ticket medio por país (Top 10):
      mean median count
```





Figura 11: Ingresos totales por segmento.



Segmento	Clientes	%	Ingresos (£)	% Ingresos	Ingreso Medio (£)
Campeones	1.295	22,13%	11.432.476	69,5%	8.828,17
Leales	689	11,77%	1.780.888	10,8%	2.584,74
En riesgo	614	10,49%	1.339.641	8,1%	2.181,83
Otros	635	10,85%	821.530	5,0%	1.293,75
Necesitan atención	2.174	37,15%	818.837	5,0%	376,65
Potenciales leales	445	7,60%	244.636	1,5%	549,74

7.4 Heatmap R vs F

Figura 12: Heatmap de ingresos por Recencia y Frecuencia.

```

3 1157
4 1172
5 1184
Name: count, dtype: int64

Distribución de puntuaciones F:
F_Score
1 1171
2 1170
3 1170
4 1170
5 1171
Name: count, dtype: int64

Distribución de puntuaciones M:
M_Score
1 1171
2 1170
3 1170
4 1170
5 1171
Name: count, dtype: int64

=====
4. SEGMENTACIÓN DE CLIENTES
=====

Distribución de segmentos:
Segmento
Necesitan atención 2174
Campeones 1295
Leales 689
Otros 635
En riesgo 614
Potenciales leales 445
Name: count, dtype: int64

Porcentaje por segmento:
Segmento
Necesitan atención 37.15
Campeones 22.13
Leales 11.77
Otros 10.85
En riesgo 10.49
Potenciales leales 7.60
Name: count, dtype: float64


Ingresos totales por segmento:
Segmento
Campeones 11432476.62
Leales 1780880.84
En riesgo 1339641.67
Otros 821530.97
Necesitan atención 818837.41
Potenciales leales 244636.22
Name: Monetary, dtype: float64

Ingreso medio por cliente en cada segmento:
Segmento
Campeones 8828.17
Leales 2584.74
En riesgo 2181.83
Otros 1293.75
Potenciales leales 549.74
Necesitan atención 376.65
Name: Monetary, dtype: float64

[ Guardado: 10_rfm_segmentos.csv ]

=====
5. GENERANDO VISUALIZACIONES
=====
[ Guardado: 18_distribucion_segmentos.png ]
[ Guardado: 19_ingresos_por_segmento.png ]

```



Hallazgo: la zona de mayor valor (R alto, F alto) acumula **£8.032.700** en ingresos.

7.5 Dispersión Recencia vs Monetario

 **Figura 13:** Dispersión de clientes por Recencia y Monetario, coloreados por segmento.

```
4 1172
5 1184
Name: count, dtype: int64

Distribución de puntuaciones F:
F_Score
1 1171
2 1170
3 1170
4 1170
5 1171
Name: count, dtype: int64

Distribución de puntuaciones M:
M_Score
1 1171
2 1170
3 1170
4 1170
5 1171
Name: count, dtype: int64

=====
4. SEGMENTACIÓN DE CLIENTES
=====

Distribución de segmentos:
Segmento
Necesitan atención 2174
Campeones 1205
Leales 689
Otros 635
En riesgo 614
Potenciales leales 445
Name: count, dtype: int64


Porcentaje por segmento:
Segmento
Necesitan atención 37.45
Campeones 22.13
Leales 11.77
Otros 10.85
En riesgo 10.49
Potenciales leales 7.60
Name: count, dtype: float64

Ingresos totales por segmento:
Segmento
Campeones 11432476.62
Leales 1780888.84
En riesgo 1339641.67
Otros 821530.97
Necesitan atención 818837.41
Potenciales leales 244636.22
Name: Monetary, dtype: float64

Ingreso medio por cliente en cada segmento:
Segmento
Campeones 8820.17
Leales 2584.74
En riesgo 2181.83
Otros 1293.75
Potenciales leales 549.74
Necesitan atención 376.65
Name: Monetary, dtype: float64


☑ Guardado: 10_rfm_segmentos.csv

=====
5. GENERANDO VISUALIZACIONES
=====
☑ Guardado: 18_distribucion_segmentos.png
☑ Guardado: 19_ingresos_por_segmento.png
☑ Guardado: 20_heatmap_rfm.png
```



7.6 Comparativa % clientes vs % ingresos

 **Figura 14:** Comparativa del porcentaje de clientes vs porcentaje de ingresos por segmento.



7.7 Hallazgos clave

Hallazgo 1: Concentración extrema en Campeones.

El 22,13% de los clientes (1.295 personas) genera el **69,5% de los ingresos** (£11,43M de £16,44M totales).

Hallazgo 2: El 37% de los clientes aporta solo el 5%.

El segmento "Necesitan atención" (2.174 clientes) apenas aporta **£818.837** (5%), con ingreso medio de £376,65.

Hallazgo 3: Los En riesgo aportan más que los Leales.

Los 614 clientes "En riesgo" generan **£1,34M**, casi lo mismo que los 689 "Leales" (£1,78M).

Hallazgo 4: El cliente más valioso genera el 3% de los ingresos.

El cliente ID 14646 ha gastado **£507.320** (3,09% del total).


8. Recomendaciones de negocio

8.1 Tabla maestra de recomendaciones

Segmento	Clientes	Ingresos (£)	Acción	Prioridad	Potencial
Campeones	1.295	11.432.476	Programa VIP	ALTA	Retener £11,4M/año

Leales	689	1.780.888	Upselling	MEDIA-ALTA	+£356.000
En riesgo	614	1.339.641	Reactivación urgente	ALTA	+£400.000
Necesitan atención	2.174	818.837	Segunda compra	MEDIA	+£409.418
Potenciales leales	445	244.636	Email nurturing	MEDIA	+£89.000
Otros	635	821.530	Análisis manual	BAJA	Optimización

 **Figura 15:** Matriz de priorización: clientes vs ingresos por segmento.



8.2 Recomendación 1: Programa VIP para Campeones

Perfil: 1.295 clientes (22,13%) → £11,43M (69,5% de ingresos).

Acción:

- Acceso anticipado a nuevos productos.
- Regalos exclusivos en fechas clave.

- Atención personalizada (gestor de cuenta para TOP 50).
- Envíos gratuitos y devoluciones sin coste.

Objetivo: mantener tasa de retención >90%.

Impacto: proteger £11,4M anuales.

8.3 Recomendación 2: Reactivación urgente para En riesgo

Perfil: 614 clientes → £1,34M de ingresos históricos.

Acción:

- Email personalizado "Te echamos de menos".
- Descuento del 15% + envío gratuito.
- Plazo limitado de 7 días.

Objetivo: recuperar el 30% del segmento.

Impacto: +£400.000.

8.4 Recomendación 3: Segunda compra para Necesitan atención

Perfil: 2.174 clientes (37,15%) → £818.837 (5% de ingresos).

Acción:

- Cupón de £10 por primera repetición.
- Recomendaciones personalizadas.
- Contenido de valor (guías, ideas).

Objetivo: convertir el 20% en Potenciales leales.

Impacto: +£409.418.

8.5 Recomendación 4: Upselling para Leales

Perfil: 689 clientes → £1,78M. Ingreso medio: £2.585.

Acción:

- Cross-selling: packs con productos complementarios.
- Suscripciones mensuales.
- Programas de puntos.

Objetivo: aumentar ticket medio un 20%.

Impacto: +£356.000.

8.6 Recomendación 5: Nurturing para Potenciales leales

Perfil: 445 clientes → £244.636.

Acción:

- Email nurturing con contenido.
- Incentivos progresivos.

- Programas de recomendación.

Objetivo: aumentar frecuencia a 3+ pedidos.

Impacto: +£89.000.

8.7 Recomendación 6: Expansión internacional

Hallazgo: Países Bajos y Australia tienen ticket medio muy superior a la media.

Acción: adaptar la estrategia comercial (idioma, logística, pago) para captar clientes en estos mercados.

8.8 Recomendación 7: Planificación estacional

Hallazgo: ingresos triplicados en oct-nov-dic; caída en enero-febrero.

Acción:

- Reforzar stock y logística en Q4.
- Campañas de "vuelta a la rutina" en enero.
- Promociones semanales los jueves.

8.9 Impacto potencial combinado

Acción	Impacto estimado
Reactivación En riesgo	+£400.000
Segunda compra Necesitan atención	+£409.418
Upselling Leales	+£356.000
Total	£1.165.418

Inversión estimada: £50.000.

ROI: 23x.

9. KPIs de seguimiento

KPI	Valor Actual	Objetivo	Plazo
Tasa de retención de Campeones	>90%	Mantener >90%	Continuo
Tasa de reactivación de En riesgo	0%	Recuperar 30%	3 meses
Conversión Necesitan atención → Leales	0%	Convertir 20%	6 meses
Ticket medio global	£19,23	Aumentar a £22,11	6 meses
Ingreso medio por cliente	£2.808,96	Aumentar a £3.200	12 meses
Nº de pedidos por cliente	6,26	Aumentar a 7,5	12 meses
Tasa de recompra a 90 días	No medido	Superar 25%	3 meses

10. Conclusiones

El análisis del dataset Online Retail II ha permitido identificar **patrones claros de comportamiento** y **oportunidades de negocio cuantificables**. Los principales aprendizajes son:

1. **La concentración de ingresos es extrema:** unos pocos clientes (Campeones) generan la mayoría de los ingresos. Esto implica **riesgo** (dependencia) y **oportunidad** (foco).
2. **El volumen vende más que el precio:** la correlación Quantity ↔ TotalPrice es significativamente mayor que UnitPrice ↔ TotalPrice.
3. **La estacionalidad es determinante:** los ingresos se triplican en el Q4. La planificación logística y de marketing debe adaptarse a este ciclo.
4. **Existen mercados internacionales de alto valor:** aunque UK domina en volumen, Países Bajos y Australia tienen ticket medio más alto.
5. **La segmentación RFM permite acciones precisas:** no todos los clientes merecen la misma inversión. Los recursos deben priorizarse según el valor y el riesgo.

Las **7 recomendaciones propuestas** tienen un **impacto potencial combinado de £1,16M** en 12 meses (7,1% de crecimiento) con una inversión estimada de £50.000 (ROI 23x).

11. Anexos

Anexo A: Estructura del repositorio